

Інтелектуальна система для ретросинтезу органічних сполук

Інтелектуальна система для ретросинтезу органічних сполук.....	1
РОЗДІЛ 1 ТЕОРЕТИЧНІ ОСНОВИ ПОБУДОВИ ІНТЕЛЕКТУАЛЬНИХ СИСТЕМ РЕТРОСИНТЕТИЧНОГО АНАЛІЗУ	4
1.1 Еволюція методів комп'ютерного планування синтезу.....	4
1.2 Способи подання хімічної інформації (SMILES) для обробки нейромережевими моделями.....	6
1.3 Топологія та принципи роботи Трансформерів і великих мовних моделей у хімії.....	8
1.4 Визначення вимог до сучасної інтелектуальної системи ретросинтезу.....	10
РОЗДІЛ 2 АНАЛІЗ МЕТОДІВ ТА МОДЕЛЕЙ ШТУЧНОГО ІНТЕЛЕКТУ ДЛЯ ЗАДАЧ РЕТРОСИНТЕЗУ	13
2.1 Аналіз моделей прямого передбачення та проблеми базових LLM.....	13
2.2 Застосування методів навчання в контексті та генерації з доповненим пошуком.....	15
2.3 Роль методів покрокового міркування для забезпечення пояснюваності рішень.....	18
2.4 Обґрунтування вибору гібридного підходу для розроблюваної інтелектуальної системи.....	20
РОЗДІЛ 3 ПРОЄКТУВАННЯ АРХІТЕКТУРИ ІНТЕЛЕКТУАЛЬНОЇ СИСТЕМИ РЕТРОСИНТЕЗУ	23
3.1 Загальна концептуальна схема розроблюваної системи.....	23
3.2 Проектування підсистеми структурно-текстового пошуку на основі молекулярних відбитків.....	26
3.3 Розробка стратегії формування підказок для забезпечення хімічного міркування.....	30
3.4 Алгоритм взаємодії компонентів інтелектуальної системи під час генерації реакцій.....	33
РОЗДІЛ 4 ОЦІНКА ЕФЕКТИВНОСТІ ТА ВАЛІДАЦІЯ ЗАПРОПОНОВАНОЇ ІНТЕЛЕКТУАЛЬНОЇ СИСТЕМИ.....	36
4.1 Методика тестування та перелік метрик.....	36
4.2 Порівняльний аналіз якості генерації базової моделі та запропонованої інтелектуальної системи.....	38
4.3 Аналіз впливу міркувань на зрозумілість та надійність результатів для експертів-хіміків.....	40
РОЗДІЛ 5 ФУНКЦІОНАЛЬНО-ВАРТІСНИЙ АНАЛІЗ ПРОГРАМНОГО ПРОДУКТУ	44
5.1 Постановка задачі проектування.....	44

5.2 Обґрунтування функцій програмного продукту.....	44
5.3 Обґрунтування системи параметрів програмного продукту.....	44
5.4 Аналіз експертного оцінювання параметрів.....	44
5.5 Аналіз рівня якості варіантів реалізації функцій.....	44
5.6 Вибір кращого варіанту програмного продукту техніко-економічного рівня	44
ПЕРЕЛІК ПОСИЛАНЬ.....	45

РОЗДІЛ 1 ТЕОРЕТИЧНІ ОСНОВИ ПОБУДОВИ ІНТЕЛЕКТУАЛЬНИХ СИСТЕМ РЕТРОСИНТЕТИЧНОГО АНАЛІЗУ

1.1 Еволюція методів комп'ютерного планування синтезу

Органічний синтез є фундаментальною основою для розробки нових фармацевтичних препаратів, агрохімікатів та передових матеріалів. Історично відкриття нових молекул та розробка маршрутів їх отримання значною мірою спиралися на експериментальні підходи, засновані на методі проб і помилок [1]. Для синтезу цільової хімічної сполуки необхідно визначити серію відповідних реакційних кроків у зворотному напрямку – від складної цільової молекули до простіших, комерційно доступних вихідних реагентів. Цей процес був концептуалізований і формалізований Е. Дж. Корі як ретросинтетичний аналіз, що стало потужним поштовхом до розвитку систем комп'ютерного планування синтезу (Computer-Assisted Synthesis Planning, CASP) та принесло вченому Нобелівську премію [2].

Незважаючи на ранні успіхи, перехід від ручного планування до повністю автоматизованих обчислювальних методів тривалий час стримувався низкою фундаментальних проблем. Головною перешкодою стало явище «комбінаторного вибуху», оскільки кількість потенційних варіантів розриву зв'язків та утворення проміжних сполук експоненційно зростає з кожним новим кроком ретросинтезу. Ранні комп'ютерні програми переважно покладалися на закодовані вручну шаблони реакцій та узагальнені експертні правила. Проте такий шаблонний підхід має суттєві недоліки: алгоритми зіставлення підграфів (subgraph matching) є обчислювально витратними, а створення та постійна підтримка спеціалізованих баз даних експертних правил вимагає колосальних людських ресурсів [1]. Крім того, жорсткі

правила обмежують здатність класичних систем генерувати інноваційні шляхи синтезу для раніше не досліджених хімічних просторів.

Зміна парадигми в ретросинтетичному аналізі відбулася завдяки стрімкому розвитку методів глибинного навчання (Deep Learning) та впровадженню архітектур обробки природної мови (NLP). Завдяки поданню молекул у вигляді лінійних текстових рядків за допомогою структурних нотацій, таких як SMILES (Simplified Molecular Input Line Entry System) або SELFIES (SELF-referencing Embedded Strings), хімічні структури почали розглядатися як лінгвістичні послідовності (токени). Це дозволило застосувати архітектуру Трансформерів (Transformers) та великі мовні моделі (Large Language Models, LLM) безпосередньо для задач хімії. Такі моделі здатні вивчати неявну хімічну «граматику» та механізми перетворень безпосередньо з великих масивів даних, перетворюючи ретросинтез із задачі графового пошуку на задачу нейро-машинного перекладу (sequence-to-sequence) [1].

Водночас застосування базових великих мовних моделей «з коробки» виявило їхні суттєві обмеження. Оскільки хімічні подання (SMILES) фундаментально відрізняються від природної мови, на якій переважно тренуються LLM, моделі часто стикаються з проблемою нездатності глибоко міркувати над просторовою структурою молекул та їхніми фізико-хімічними властивостями. Як наслідок, під час прямого передбачення реакцій (zero-shot) базові моделі схильні до генерації хімічно невалідних структур, невідповідностей стехіометрії та стереохімічних помилок, що в сукупності класифікується як проблема «галюцинацій» моделі [1], [3].

З огляду на це, сучасною вимогою до побудови надійних інтелектуальних систем ретросинтезу є відмова від використання LLM як ізольованих модулів на користь гібридних архітектур. Передові наукові

дослідження доводять, що дієва система повинна інтегрувати механізми генерації з доповненим пошуком (Retrieval-Augmented Generation, RAG), які збагачують вхідний запит моделі релевантним структурним контекстом та прецедентами зі спеціалізованих баз даних. Крім того, критично важливим є стимулювання моделі до покрокового міркування (Chain-of-Thought, CoT), що змушує алгоритм детально аналізувати реакційні центри, функціональні групи та можливі побічні ефекти перед видачею кінцевого прогнозу. Такий комплексний підхід є життєво необхідним для створення інтелектуальної системи, яка не лише генерує високоточні прогнози, а й забезпечує достатній рівень прозорості та пояснюваності рішень для експертів-хіміків.

1.2 Способи подання хімічної інформації (SMILES) для обробки нейромережевими моделями

Для успішного застосування передових методів обробки природної мови (NLP), зокрема архітектур на базі Трансформерів та великих мовних моделей (LLM), у задачах комп'ютерної хімії необхідно перетворити структурну хімічну інформацію у текстовий формат [1], [4]. Оскільки традиційні молекулярні графи важко безпосередньо інтегрувати в класичні мовні моделі, сучасною парадигмою є використання лінійних текстових нотацій (mol-based inputs), що дозволяє розглядати хімічні структури як лінгвістичні послідовності [1], [5].

Найбільш поширеним стандартом подання молекул у комп'ютерній хімії є система SMILES. Ця система перетворює молекулярні структури на текстовий рядок на основі визначених правил: атоми позначаються їхніми хімічними символами, типи зв'язків – спеціальними знаками, а цикли та розгалуження – відповідними дужками чи цифрами [6]. Наприклад, в рамках

цієї нотації молекула етанолу кодується як «CCO», а оцтова кислота – як «CC(=O)O» [1].

Попри свою популярність, система SMILES має певні недоліки під час генерації: не кожна випадкова комбінація символів формує хімічно валідну молекулу, тому для підвищення надійності обчислень було розроблено альтернативну нотацію SELFIES. Нотація SELFIES розроблена таким чином, щоб бути на 100% стійкою (robust), тобто будь-яка згенерована нею послідовність гарантовано відповідає валідній молекулярній структурі [1]. Також для стандартизації молекулярних даних в хімічних базах часто використовують ідентифікатори InChI (IUPAC International Chemical Identifier) [5].

Процес обробки таких хімічних рядків нейромережевими моделями розпочинається з етапу токенизації, під час якого рядок розбивається на окремі елементи (токени), які входять до словника моделі [1], [5]. Для цього можуть застосовуватися як посимвольні методи, так і складніші алгоритми токенизації, такі як SentencePiece, які ефективніше обробляють хімічні підструктури та мотиви [4].

Після токенизації кожен токен перетворюється на числовий вектор у процесі, який називається векторним вкладенням (input embedding), що розміщує токени у безперервному семантичному просторі [7]. Оскільки Трансформери паралельно обробляють дані і не мають вбудованого розуміння порядку елементів у послідовності, до векторних вкладень обов'язково додається позиційне кодування (positional encoding) на основі тригонометричних функцій або вивчених параметрів. Позиційне кодування зберігає інформацію про відносне або абсолютне положення токена в хімічному рядку, що дозволяє моделям на базі механізму уваги (attention)

розпізнавати складні хімічні взаємозв'язки та довгострокові закономірності під час прогнозування реакцій [5].

1.3 Топологія та принципи роботи Трансформерів і великих мовних моделей у хімії

Фундаментом сучасних великих мовних моделей (LLM) є архітектура Трансформер (Transformer), яка здійснила революцію у комп'ютерній хімії завдяки здатності паралельно обробляти послідовності та фіксувати складні залежності у даних. На відміну від попередніх рекурентних нейронних мереж (RNN), які обробляли токени послідовно і страждали від проблеми зникаючого градієнта, Трансформери повністю покладаються на механізм багатоголової уваги (multi-head attention). У контексті хімічних нотацій (наприклад, SMILES) цей механізм обчислює ступінь кореляції між усіма атомами та структурними фрагментами молекули. Це дозволяє моделі ефективно розпізнавати довгострокові хімічні зв'язки, такі як замикання кілець або взаємний вплив віддалених функціональних груп [5] [7].

Оскільки Трансформери обробляють усі елементи послідовності одночасно, вони не мають вбудованого розуміння порядку символів. Для розв'язання цієї проблеми до векторних вкладень (ембеддингів) хімічних токенів додається позиційне кодування (positional encoding), що зберігає інформацію про відносне положення атомів у молекулі. Сама ж архітектура складається зі складених шарів, які містять механізми уваги, повнозв'язні нейронні мережі (feed-forward networks) та залишкові зв'язки (residual connections) для стабілізації процесу навчання [5].

Залежно від наявності та комбінації основних блоків, нейромережеві моделі у хімії класифікуються на три основні топології:

1. Моделі на базі кодувальника (Encoder-only). До цієї категорії належать такі архітектури, як BERT, ChemBERTa та SMILES-BERT. Вони перетворюють вхідну хімічну послідовність на глибоке контекстне векторне подання, аналізуючи рядок двоспрямовано. Такі моделі є найефективнішими для задач вилучення знань, класифікації хімічних реакцій та прогнозування властивостей молекул (property prediction), наприклад, розчинності чи токсичності [1], [5].

2. Моделі на базі декодувальника (Decoder-only). Ця топологія є основою для більшості сучасних генеративних LLM, таких як GPT, LLaMA та спеціалізованих хімічних моделей (ChemLLM, ChemDFM). Декодери працюють авторегресійно, тобто генерують кожен наступний токен на основі попередніх. У хімії такі архітектури ідеально підходять для задач спрямованої генерації нових молекул із заданими властивостями (de novo design). Крім того, завдяки здатності до генерації зв'язного тексту, декодерні моделі можуть виступати інтелектуальними агентами, здатними пояснювати свої рішення та формувати покрокові ланцюжки хімічних міркувань (Chain-of-Thought) для розв'язання нетипових задач [1], [5], [6].

3. Архітектури кодувальник-декодувальник (Encoder-Decoder або seq2seq). Моделі типу T5 та BART (наприклад, MolT5, ReactionT5) поєднують переваги обох попередніх топологій. Ця архітектура традиційно використовується для задач «нейро-машинного перекладу». У контексті ретросинтетичного аналізу кодувальник аналізує цільову молекулу-продукт, а декодувальник крок за кроком генерує відповідну послідовність прекурсорів (реагентів). Завдяки такій топології моделі можуть ефективно транслювати хімічні перетворення з високою точністю [4], [5].

Підсумовуючи, вибір та розуміння топології мовної моделі є фундаментальним кроком під час проєктування сучасної інтелектуальної

системи. Хоча моделі типу seq2seq демонструють високу ефективність у прямій трансляції реакцій, сучасні дослідження все частіше спираються на потужні авторегресійні LLM (Decoder-only), які, завдяки інтеграції з методами доповненого пошуку (RAG) та інженерією підказок, здатні вирішувати задачі ретросинтезу з вищим рівнем хімічної обґрунтованості та пояснюваності [5].

1.4 Визначення вимог до сучасної інтелектуальної системи ретросинтезу

Аналіз еволюції методів комп'ютерного планування синтезу та особливостей нейромережових архітектур дозволяє стверджувати, що застосування базових великих мовних моделей (LLM) «з коробки» є недостатнім для розв'язання складних хімічних задач. Попри високу здатність LLM до генерації тексту, їх ізольоване застосування часто призводить до хімічно невалідних результатів, стереохімічних помилок та ігнорування важливих умов реакції через недостатню спеціалізовану хімічну підготовку [1]. З огляду на це, сучасна інтелектуальна система ретросинтетичного аналізу повинна відповідати низці жорстких архітектурних та функціональних вимог, що базуються на передових дослідженнях у галузі штучного інтелекту.

Першою ключовою вимогою є здатність системи долати обмеження статичної пам'яті базової моделі та мінімізувати явище «галюцинацій». Для цього архітектура системи має обов'язково інтегрувати механізм генерації з доповненим пошуком (Retrieval-Augmented Generation, RAG) [3], [5]. Замість того, щоб покладатися виключно на внутрішні ваги нейромережі, інтелектуальна система повинна в режимі реального часу звертатися до

зовнішніх баз знань (наприклад, наборів патентних реакцій USPTO або відкритої бази ORD) для пошуку релевантних хімічних прецедентів [4], [8]. Використання структурного пошуку на основі молекулярних відбитків (reaction fingerprints) та обчислюваних фізико-хімічних дескрипторів дозволяє збагатити вхідний запит моделі контекстом про структурно схожі молекули, що суттєво підвищує надійність згенерованих шляхів синтезу [3].

Другою критичною вимогою є забезпечення прозорості (пояснюваності) прийнятих рішень. Традиційні нейромережеві моделі типу «чорний ящик» не викликають достатньої довіри в експертів-хіміків, оскільки вони не здатні пояснити внутрішню логіку вибору розриву тих чи інших хімічних зв'язків [6]. Сучасна система повинна імітувати когнітивний процес фахівця, застосовуючи метод покрокового міркування (Chain-of-Thought, CoT) [1]. Це означає, що перед видачею кінцевого результату алгоритм має згенерувати розгорнуте текстове пояснення: проаналізувати цільову молекулярну структуру, ідентифікувати ключові функціональні групи та можливі реакційні центри, а також обґрунтувати вибір конкретного шляху розщеплення з огляду на термодинамічну доцільність та кінетичні обмеження [2].

Третьою вимогою є комплексне розуміння та генерація умов проведення хімічної реакції. Ретросинтетичний аналіз не обмежується лише пошуком хімічних прекурсорів; для успішного відтворення реакції в лабораторії (або в автономних роботизованих системах) система повинна пропонувати повний хімічний контекст. Згенеровані рішення повинні обов'язково містити інформацію про необхідні розчинники, каталізатори, температурні режими, час проведення реакції та очікуваний вихід продукту. Це вимагає від системи використання суворих шаблонів промптингу (Prompt

Engineering) та алгоритмів вирівнювання (наприклад, Direct Preference Optimization), які контролюють структурну повноту відповідей моделі [6].

Підсумовуючи, розроблювана інтелектуальна система не повинна бути просто генератором послідовностей SMILES. Її архітектура має являти собою складний гібридний конвеєр, у якому велика мовна модель виступає як аналітичне ядро, підсилене зовнішньою пам'яттю (векторними базами даних та алгоритмами RAG) та жорстко кероване механізмами покрокового логічного висновку [2], [3]. Саме такий комплексний підхід дозволить створити надійний інструмент для хіміків-дослідників і є концептуальною основою для проєктування архітектури в наступних розділах даної роботи.

РОЗДІЛ 2 АНАЛІЗ МЕТОДІВ ТА МОДЕЛЕЙ ШТУЧНОГО ІНТЕЛЕКТУ ДЛЯ ЗАДАЧ РЕТРОСИНТЕЗУ

2.1 Аналіз моделей прямого передбачення та проблеми базових LLM

Для автоматизації ретросинтетичного аналізу в останні роки широко застосовуються моделі прямого передбачення, які розглядають задачу перетворення цільової молекули-продукту на прекурсори як процес нейро-машинного перекладу або авторегресійної генерації тексту [1]. Серед сучасних архітектур, що демонструють високу ефективність у цій галузі, варто виділити спеціалізовані моделі ReactionT5 та Chemma.

Модель ReactionT5 базується на архітектурі кодувальник-декодувальник (seq2seq) і розроблена спеціально для прогнозування хімічних реакцій в умовах обмежених тренувальних даних. Навчання цієї моделі відбувається у два етапи: спочатку базова модель T5 проходить попереднє тренування на великій бібліотеці окремих молекул (модуль CompoundT5), засвоюючи базовий хімічний синтаксис. На другому етапі модель навчається безпосередньо на базі даних хімічних реакцій, вивчаючи складні взаємозв'язки між реагентами, розчинниками, каталізаторами та продуктами. У результаті ReactionT5 здатна ефективно виконувати одразу кілька завдань у форматі text-to-text, зокрема пряме передбачення продуктів, ретросинтетичний аналіз та прогнозування виходу реакції. Проте, як класична модель трансляції послідовностей, вона фокусується на лінійному відображенні вхідного рядка на вихідний і має обмежені можливості для забезпечення прозорості логічного висновку чи формування розгорнутих пояснень своїх рішень [4].

Альтернативним підходом є використання потужних авторегресійних великих мовних моделей (Decoder-only), яскравим прикладом яких є система Chemma. Побудована на базі архітектури LLaMA-2, модель Chemma проходить етап контрольованого точного налаштування (Supervised Fine-Tuning, SFT) на масивах специфічних хімічних завдань. Її визначною інновацією є застосування методів навчання з підкріпленням на основі відгуків (RLHF) та побудова моделі винагород (Reward Model) для цілеспрямованої оптимізації умов реакцій. Завдяки такій архітектурі Chemma здатна не лише генерувати кроки ретросинтезу, а й вести діалог з дослідником, рекомендуючи оптимальні ліганди, бази чи розчинники для підвищення виходу цільового продукту [9].

Незважаючи на значний науковий прогрес, застосування базових великих мовних моделей (і навіть спеціалізованих хімічних LLM на кшталт Chemma та ReactionT5) у якості ізольованих систем стикається з фундаментальними недоліками. Головною проблемою є схильність мовних моделей до хімічних «галюцинацій». Оскільки LLM навчаються переважно на текстових даних і лінійних нотаціях (SMILES), вони не володіють вбудованим фізичним розумінням тривимірної структури молекул, їхніх електронних властивостей чи термодинамічних законів [1]. Це призводить до того, що під час прямого передбачення (zero-shot) моделі можуть генерувати хімічно невалідні структури, пропонувати розрив неможливих хімічних зв'язків, порушувати правила збереження маси (стехіометрію) або припускатися критичних стереохімічних помилок [6].

Другим суттєвим недоліком є проблема «сліпоти до умов» (condition blindness) або часткова втрата контексту хімічного середовища. Традиційно ретросинтетичний аналіз у комп'ютерних програмах зводиться лише до передбачення SMILES-рядків прекурсорів [1]. Однак в органічному синтезі

можливість та успішність проведення конкретної трансформації критично залежить від наявності правильного каталізатора, розчинника та температурного режиму. Без точного зазначення цих параметрів запропонований ретросинтетичний крок залишається теоретичною абстракцією, яку часто неможливо відтворити в реальній лабораторії. Крім того, класичні LLM обмежені знаннями, зафіксованими у їхніх статичних тренувальних вибірках на момент навчання, через що вони погано генерують надійні рішення для нових, раніше не досліджених реакційних просторів або рідкісних класів сполук [8].

Таким чином, результати аналізу сучасних моделей прямого передбачення свідчать, що хоча вони і здатні ефективно вилучати неявну хімічну «граматику» та генерувати правдоподібні послідовності реакцій, їхня схильність до галюцинацій та нездатність комплексно обґрунтовувати умови синтезу без залучення зовнішніх даних суттєво обмежує їх автономність. Це доводить необхідність переходу від архітектур прямого передбачення «з коробки» до створення гібридних інтелектуальних систем, які б компенсували ці недоліки шляхом інтеграції зовнішніх баз знань та методів покрокового міркування [1], [8].

2.2 Застосування методів навчання в контексті та генерації з доповненим пошуком

Для подолання фундаментальних обмежень базових мовних моделей, таких як проблема «галюцинацій» та нездатність враховувати складний фізико-хімічний контекст під час передбачення реакцій, сучасні дослідження зміщують фокус на методи динамічного збагачення моделей зовнішніми знаннями. Найефективнішими підходами у цьому напрямі є навчання в

контексті (In-Context Learning, ICL) та архітектури генерації з доповненим пошуком (Retrieval-Augmented Generation, RAG).

Метод навчання в контексті (ICL) дозволяє великим мовним моделям адаптуватися до виконання специфічних завдань завдяки аналізу кількох демонстраційних прикладів, наданих безпосередньо у вхідному запиті (промпті), без необхідності оновлення ваг самої нейромережі. У задачах комп'ютерної хімії цей підхід реалізовано, зокрема, в архітектурі FusionRetro. Дана система використовує ICL для об'єднання (fusion) подань молекул, застосовуючи багатоголовий механізм уваги (multi-head attention) для трансформації вхідних рядків SMILES у приховані репрезентації. На відміну від традиційних шаблонних чи напівшаблонних методів, FusionRetro динамічно обчислює коефіцієнти кореляції між цільовою молекулою та знайденими контекстними прикладами, що дозволяє передавати інформацію через зважений граф реакцій у більш змістовний спосіб. Це суттєво підвищує точність передбачення ретросинтетичних шляхів, особливо для складних молекул із декількома реакційними центрами [7].

Розвиток ідеї контекстного збагачення призвів до створення систем генерації з доповненим пошуком (RAG). Замість того, щоб покладатися виключно на внутрішні знання, збережені у параметрах моделі під час її попереднього навчання, RAG-фреймворки в режимі реального часу вилучають релевантну інформацію з масштабних зовнішніх баз даних. Відмінним прикладом є система MolE-RAG, яка не обмежується єдиним джерелом контексту, а доповнює кожен запит до LLM трьома взаємодоповнюючими типами інформації: текстовою хімічною літературою (вилученою за допомогою алгоритму BM25), структурно схожими молекулами (визначеними на основі навчальної вибірки) та специфічними молекулярними дескрипторами. Додавання ідентифікаторів сполук

(наприклад, синонімів та назв за IUPAC), анотацій функціональних груп та розрахованих фізико-хімічних дескрипторів (на базі бібліотеки RDKit) забезпечує надійне "заземлення" (grounding) моделі в реальній хімії. Оцінювання показує, що залучення знайдених прикладів і молекулярних дескрипторів ефективно калібрує простір передбачень моделі, зменшуючи середню похибку та мінімізуючи появу екстремальних хімічних галюцинацій [3].

Найвищого рівня інтеграції досягають гібридні системи на кшталт ReactGPT, які поєднують розширений пошук реакцій із цілеспрямованим донавчанням моделей. ReactGPT складається з трьох ключових компонентів: пошуку реакцій на основі молекулярних відбитків (Fingerprints-based Reaction Retrieval), дизайну предметно-орієнтованих підказок (Domain-Specific Prompt Design) та двоетапного налаштування в контексті (Two-stage In-Context Tuning). Використовуючи спеціалізовані моделі (наприклад, Rxnfp) для кодування реакцій у векторні відбитки, система знаходить найбільш подібні приклади «реакція-опис» із тренувального набору. Ці контекстні приклади передаються в LLM: чим вища їхня структурна подібність до запиту, тим більше перекриття у реагентах та умовах проведення спостерігається, що критично покращує достовірність фінальної генерації [6].

Щоб подолати проблему недостатньої структурованості та відсутності ключових елементів (таких як каталізатори, розчинники, температура чи вихід продукту) у згенерованих маршрутах, архітектури типу ReactGPT також застосовують алгоритм прямої оптимізації преференцій (Direct Preference Optimization, DPO). На етапі вирівнювання структурних преференцій за допомогою дискримінатора формуються пари правильних і помилкових результатів, що змушує мовну модель мінімізувати неправильні відповіді та

підвищувати ймовірність генерації тих текстів, які суворо дотримуються необхідної хімічної семантики та формату [6].

Таким чином, імплементація методів ICL та RAG дозволяє ефективно компенсувати проблему "сліпоти до умов", притаманну базовим моделям прямого передбачення. Інтеграція зовнішніх баз знань зі структурною та текстовою інформацією трансформує LLM з ізольованого генератора послідовностей у повноцінну інтелектуальну систему, здатну обґрунтовувати свої передбачення наявними хімічними прецедентами.

2.3 Роль методів покрокового міркування для забезпечення пояснюваності рішень

Застосування великих мовних та seq2seq моделей у комп'ютерній хімії стикається з фундаментальною проблемою «чорного ящика». Традиційні моделі прямого передбачення генерують лише кінцевий результат (SMILES-рядки реагентів), не надаючи експертам жодної інформації про логіку прийняття рішень. Відсутність прозорості та хімічного обґрунтування знижує довіру дослідників до згенерованих маршрутів, особливо у випадках складних багатоетапних синтезів, де нетиповий розрив зв'язків потребує верифікації. Для вирішення цієї проблеми сучасні дослідження активно впроваджують методи покрокового міркування (Chain-of-Thought, CoT). Цей підхід стимулює модель розбивати складне завдання на послідовність дрібніших логічних кроків перед видачею остаточної відповіді, що дозволяє значно знизити рівень галюцинацій та підвищити інтерпретованість результатів [5].

У контексті ретросинтетичного аналізу застосування CoT вимагає від моделі спочатку проаналізувати структурні особливості цільової молекули,

ідентифікувати ключові функціональні групи та можливі реакційні центри, оцінити термодинамічну доцільність розриву зв'язків і лише після цього формувати кінцевий прогноз. Передовим прикладом реалізації такого підходу є інтелектуальна система RetroDFM-R (Reasoning-Driven Retrosynthesis Prediction). Вона використовує спеціально налаштовану архітектуру LLM для генерування розгорнутих пояснень (reasoning traces) паралельно з передбаченням хімічних прекурсорів [2].

Процес навчання та оптимізації моделі RetroDFM-R складається з трьох ключових етапів, що забезпечують її здатність до глибокого хімічного аналізу:

1. Безперервне попереднє навчання (Continual Pretraining): модель засвоює фундаментальні хімічні знання та синтаксис на основі специфічних баз даних, релевантних для ретросинтезу.

2. Дистиляція міркувань із "холодним стартом" (Cold-Start Distillation): на цьому етапі використовується потужніша модель загального призначення для генерації високоякісних логічних ланцюжків за умови відомої правильної відповіді (answer-conditioned). Навчання на цих даних ініціалізує здатність системи RetroDFM-R формувати послідовні міркування, що імітують когнітивний процес хіміка-експерта.

3. Навчання з підкріпленням (Reinforcement Learning): найважливіший етап, під час якого застосовується масштабний алгоритм оптимізації політики (DAPO). Модель оптимізується за допомогою об'єктивної функції винагороди, яка змушує систему генерувати деталізовані та хімічно обґрунтовані ретросинтетичні шляхи.

Функція винагороди на етапі навчання з підкріпленням складається з двох невід'ємних компонентів: винагороди за правильність (correctness reward) та винагороди за формат (format reward). Система жорстко контролює

структуру вихідних даних: алгоритм отримує позитивне підкріплення лише тоді, коли його відповідь містить блок міркувань у тегах `<think>...</think>` та блок із валідними SMILES-рядками реагентів у тегах `<answer>...</answer>` [2].

Завдяки такій архітектурі інтелектуальна система здатна генерувати не просто текстові послідовності, а повноцінні хімічні обґрунтування. Наприклад, у блоці міркувань модель може пояснити, що розрив зв'язку C–C доцільно провести через реакцію крос-сполучення Сузукі-Міяури, враховуючи наявність специфічних стеричних ефектів чи електроноакцепторних груп, і лише після цього запропонувати відповідні боронові кислоти та галогеніди як прекурсори [2].

Використання методології покрокового міркування перетворює LLM із генератора «сліпих» прогнозів на прозору систему штучного інтелекту. Це дозволяє експертам легко верифікувати кожен запропонований крок, суттєво підвищує загальну надійність передбачень та генерує структурно різноманітні варіанти синтезу навіть для складних цільових молекул. Інтеграція підсистеми міркування (Reasoning) є критично необхідною вимогою для проєктування сучасної надійної інтелектуальної системи ретросинтезу.

2.4 Обґрунтування вибору гібридного підходу для розроблюваної інтелектуальної системи

Аналіз існуючих підходів та методів, наведений у попередніх підрозділах, демонструє, що еволюція систем комп'ютерного планування синтезу закономірно призвела до використання великих мовних моделей. Водночас застосування LLM як ізольованих систем (наприклад, у задачах

прямого авторегресійного передбачення) має низку критичних недоліків. Попри свою лінгвістичну універсальність та здатність неявно засвоювати хімічний синтаксис на основі текстових репрезентацій (SMILES), базові моделі без належної адаптації або зовнішнього контексту часто хиблять у хімічній точності та страждають від "галюцинацій" [1]. Оскільки такі моделі не мають вбудованого розуміння фізико-хімічних законів, просторової стереохімії чи термодинамічних обмежень, вони схильні пропонувати хімічно невалідні розриви зв'язків або ігнорувати умови проведення реакцій.

З огляду на ці проблеми, першим фундаментальним обґрунтуванням для побудови надійної інтелектуальної системи є необхідність інтеграції механізмів генерації з доповненим пошуком (Retrieval-Augmented Generation, RAG) та методів навчання в контексті (In-Context Learning). Як доводять дослідження архітектур на кшталт MolE-RAG та ReactGPT, подання молекули виключно у вигляді послідовності SMILES є недостатнім для LLM, оскільки воно позбавлене зовнішнього обґрунтування. Залучення гібридного пошукового модуля, що доповнює вхідний запит текстовими даними з літератури, релевантними дескрипторами та структурно схожими молекулами-прецедентами з навчальної вибірки, дозволяє динамічно налаштовувати модель на правильний хімічний контекст. Завдяки цьому простір передбачень моделі калібрується, зменшується кількість екстремальних похибок та вирішується проблема ізольованості статичної пам'яті LLM [3], [6].

Другим обов'язковим компонентом гібридного підходу є впровадження підсистеми покрокового міркування (Chain-of-Thought, CoT). Відсутність пояснюваності рішень, відома як проблема «чорного ящика», залишається однією з головних перешкод для прийняття нейромережевих рішень хіміками-дослідниками. Сучасна інтелектуальна система не повинна

обмежуватися лише генерацією кінцевого SMILES-рядка прекурсорів. Натомість, використовуючи методологію систем типу RetroDFM-R, модель має бути стимульована до детального аналізу: вона повинна розпізнати ключові функціональні групи цільової молекули, ідентифікувати реакційні центри, оцінити термодинамічну доцільність потенційного розриву зв'язку і лише після цього запропонувати хімічно обґрунтовані та стабільні реагенти [2]. Такий підхід трансформує LLM із простого генератора тексту в прозорого аналітичного агента, чиї логічні кроки можуть бути легко верифіковані експертами.

Зважаючи на вищезазначене, концептуально обґрунтованим вибором для розроблюваної в даній дипломній роботі інтелектуальної системи є гібридна конвеєрна архітектура. Замість використання ресурсомістких графових алгоритмів багатокрокового пошуку (наприклад, AND-OR дерев), які схильні до комбінаторного вибуху та повільної збіжності [1], [2], пропонується зосередити обчислювальні зусилля на максимізації якості однокрокового ретросинтетичного аналізу.

Розроблювана система буде поєднувати потужність авторегресійної мовної моделі (як логічного ядра) зі спеціалізованою векторною базою даних для гібридного пошуку прецедентів (RAG), а також застосовувати суворі шаблони структурного промптингу (Prompt Engineering) для гарантування прозорого покрокового міркування (CoT) [2], [6]. Саме ця синергія методів генеративного штучного інтелекту здатна забезпечити високу хімічну достовірність, контекстну обізнаність та експертну пояснюваність результатів, і вона ляже в основу практичного проектування системи, що розглядається у наступному розділі даної роботи.

РОЗДІЛ 3 ПРОЄКТУВАННЯ АРХІТЕКТУРИ ІНТЕЛЕКТУАЛЬНОЇ СИСТЕМИ РЕТРОСИНТЕЗУ

3.1 Загальна концептуальна схема розроблюваної системи

Розробка ефективної інтелектуальної системи для ретросинтетичного аналізу вимагає подолання фундаментальних обмежень базових великих мовних моделей (LLM), таких як схильність до «хімічних галюцинацій» та проблема «чорного ящика». Як свідчить аналіз сучасної літератури, використання ізольованих LLM для передбачення реакцій часто призводить до генерації хімічно невалідних структур або нетипових умов, оскільки моделі бракує заземлення у реальних фізико-хімічних даних [1], [3].

З огляду на це, загальна концептуальна схема розроблюваної системи базується на гібридній конвесрній архітектурі, що поєднує генеративну потужність авторегресійної мовної моделі (топологія Decoder-only) із зовнішнім модулем генерації з доповненим пошуком (RAG) та підсистемою покрокового міркування (Chain-of-Thought) [5].

Концептуальна схема взаємодії компонентів запропонованої системи наведена на рисунку 3.1.




Рисунок 3.1 – Загальна концептуальна схема гібридної інтелектуальної системи ретросинтезу

Архітектура системи складається з трьох ключових макрокомпонентів, кожен з яких виконує специфічну функцію в процесі генерації ретросинтетичного кроку:

1. Модуль генерації з доповненим пошуком (Retrieval-Augmented Generation, RAG) Оскільки хімічний простір є надзвичайно великим, розроблювана система не покладається виключно на статичну пам'ять (ваги) мовної моделі. Модуль RAG виконує роль довгострокової пам'яті системи. При отриманні цільової молекули (у форматі SMILES) підсистема структурного пошуку обчислює її молекулярні відбитки (molecular fingerprints) та шукає в локальній базі знань (наприклад, проіндексованому наборі патентів USPTO) топ-k структурно подібних реакцій-прецедентів. Надання моделі зовнішніх доказів, таких як приклади схожих трансформацій та фізико-хімічні дескриптори, дозволяє динамічно калібрувати простір передбачень і суттєво знижує ймовірність генерації нереалістичних розривів зв'язків [3], [6].

2. Підсистема формування запитів та покрокового міркування (Prompt Engineering & CoT) Цей компонент відповідає за інтеграцію знайденого контексту з вхідними даними та жорстке управління поведінкою мовної моделі. Базуючись на передових дослідженнях систем типу ReactGPT та RetroDFM-R, запит до моделі (промпт) структурується за чітким шаблоном [2], [6]. Система не просто ставить завдання «передбачити реагенти», а імплементує техніку покрокового міркування (Chain-of-Thought). Промпт вимагає від моделі розбити складне завдання на етапи: спочатку проаналізувати вхідну структуру, виділити функціональні групи та реакційні центри, оцінити термодинамічну доцільність реакції на основі наданих RAG-прецедентів, і лише потім генерувати результат [5].

3. Ядро мовної моделі (Авторегресійний LLM Агент) У якості обчислювального та семантичного ядра системи використовується велика мовна модель з архітектурою декодувальника (Decoder-only), така як LLaMA або Qwen. Авторегресійна природа цих моделей, що генерують текст токен за токеном, є оптимальною для формування послідовних логічних ланцюжків [5]. Щоб гарантувати програмну обробку результатів (machine-readability), система спонукає модель генерувати відповідь у строго визначеному форматі: логічне обґрунтування процесу розміщується всередині текстових тегів <think>...</think>, а остаточний SMILES-рядок запропонованих прекурсорів – у тегах <answer>...</answer> [2].

3.2 Проєктування підсистеми структурно-текстового пошуку на основі молекулярних відбитків

Фундаментальним компонентом розроблюваної гібридної інтелектуальної системи є підсистема генерації з доповненим пошуком (Retrieval-Augmented Generation, RAG). Її головне завдання полягає у подоланні проблеми «сліпоти до умов» та обмеженості внутрішньої пам'яті авторегресійної мовної моделі шляхом надання їй доступу до бази перевірених хімічних прецедентів [3]. Проєктування даної підсистеми включає етапи підготовки масиву хімічних знань, векторизації молекулярних структур та розробки ефективного алгоритму пошуку найближчих сусідів (k-NN).

Як джерело зовнішніх знань у системі використовуються спеціалізовані масиви хімічних реакцій, зокрема набори даних USPTO-50K та Open Reaction Database (ORD). Вибір бази ORD є критично важливим для забезпечення якості роботи системи, оскільки на відміну від базових патентних витягів,

записи ORD містять деталізовану інформацію про реакційне середовище: розчинники, температуру в градусах Цельсія, каталізатори та фактичний вихід продукту [4]. Надання цієї інформації мовній моделі дозволяє генерувати ретросинтетичні маршрути, які є відтворюваними у реальних лабораторних умовах.

Для забезпечення можливості швидкого структурного пошуку система перетворює текстові рядки SMILES на числові вектори – молекулярні відбитки (Morgan Fingerprints). На відміну від ресурсомістких нейромережових енкодерів, відбитки Моргана базуються на алгоритмічному хешуванні структурних фрагментів молекули, що гарантує високу швидкість обчислень та інваріантність подання [3].

Унікальною архітектурною особливістю розроблюваної підсистеми RAG є гібридний метод векторного індексування бази даних. Більшість існуючих систем пошуку покладаються або виключно на схожість цільового продукту, або використовують важкі моделі типу Rxnfp для кодування всієї реакції. Натомість у запропонованій архітектурі векторна база даних (наприклад, СУБД Qdrant) розділяється на дві паралельні колекції:

1. Колекція відбитків молекул (reactions_morgan): зберігає традиційні відбитки Моргана цільових молекул-продуктів для визначення загальної глобальної структурної схожості.

2. Колекція відбитків трансформацій (reaction_transforms): зберігає спеціалізовані вектори, що кодують безпосередньо центр хімічної реакції.

Для обчислення вектора трансформації у системі спроектовано використання побітової логічної операції виключного АБО (XOR) між відбитком продукту та відбитком реагенту:

$$FP_{transform} = FP_{product} \oplus FP_{reactant}$$

Цей математичний підхід дозволяє ефективно «відняти» незмінні (інертні) частини молекули, залишаючи у векторі лише ті біти, які відповідають за розрив чи утворення нових хімічних зв'язків.

Процес структурно-текстового пошуку наведено на рисунку 3.2.




Рисунок 3.2 – Архітектура та алгоритм роботи підсистеми структурно-текстового пошуку (RAG)

Алгоритм вилучення даних під час ретросинтетичного аналізу працює наступним чином. Коли система отримує цільову молекулу-запит (Query),

вона генерує її векторний відбиток. Далі виконується паралельний пошук у векторній СУБД для знаходження k-найближчих сусідів. Для оцінки ступеня подібності між запитом та молекулами у базі використовується коефіцієнт Танімото (Tanimoto similarity) [3]. Після отримання попередніх результатів модуль ранжування застосовує гібридну метрику, що комбінує оцінку структурної подібності продуктів та оцінку подібності реакційних трансформацій.

Найкращі k реакцій-прецедентів вилучаються з бази разом із текстовими метаданими (SMILES реагентів, розчинниками, каталізаторами) і передаються у підсистему інженерії підказок як контекст для мовної моделі. Такий підхід гарантує, що мовна модель під час генерації спиратиметься не на випадкові галюцинації, а на хімічно обґрунтовані патентні та літературні дані.

3.3 Розробка стратегії формування підказок для забезпечення хімічного міркування

Стратегія формування підказок (Prompt Engineering) є критично важливим етапом проектування сучасних інтелектуальних систем на базі великих мовних моделей. Оскільки базові авторегресійні моделі навчаються на масивах текстів загального призначення, пряме (zero-shot) прогнозування складних хімічних структур часто призводить до генерації невалідних SMILES-рядків або хімічно необґрунтованих реакцій [6]. Для вирішення цієї проблеми у розроблюваній системі застосовується жорстко структурований шаблон підказки, який поєднує методи навчання в контексті (In-Context Learning, ICL) та стимулювання до покрокового міркування (Chain-of-Thought, CoT).

Відповідно до передових досліджень у галузі хімічного промптингу [3], [6], [10], структуру вхідного запиту до мовної моделі поділено на чотири функціональні макрокомпоненти:

1. Рольове визначення та опис завдання (Role & Task Description). На початку підказки моделі задається системний контекст (наприклад, «Ви – експерт у галузі органічної хімії та ретросинтетичного аналізу»). Далі формалізується саме завдання: системі вказується необхідність знайти попередники для заданої цільової молекули-продукту, дотримуючись правил збереження маси, стереохімії та стехіометрії [2], [10].

2. Інтеграція контекстних прикладів (Context Examples). Цей компонент є сполучною ланкою між підсистемою RAG (описаною в підрозділі 3.2) та мовною моделлю. Знайдені у векторній базі Топ-к найсхожіших реакцій-прецедентів динамічно вбудовуються у промпт. Кожен приклад містить опис умов реакції, каталізаторів, розчинників та відповідних SMILES-рядків. Надання таких доказів під час виконання логічного висновку суттєво зменшує явище «галюцинацій», оскільки модель спирається на емпіричні патентовані або літературні дані

3. Вимога покрокового міркування (Reasoning / Chain-of-Thought). Замість прямої генерації результату, система застосовує алгоритм, натхненний архітектурою RetroDFM-R, зобов'язуючи модель спочатку детально проаналізувати задачу [2]. У підказці міститься пряма інструкція: ідентифікувати ключові функціональні групи цільової молекули, оцінити реакційні центри, стеричні чи резонансні ефекти, обґрунтувати вибір конкретного шляху розриву зв'язків та проаналізувати кінетичну/термодинамічну доцільність цього кроку.

4. Форматування виводу (Structured Output Format). Для забезпечення інтеграції мовної моделі з програмним інтерфейсом системи

(machine-readability) застосовуються суворі структурні обмеження. Модель повинна генерувати відповідь із використанням спеціальних маркерів (тегів).

Для реалізації останньої вимоги розроблено наступний синтаксичний шаблон генерації відповіді:

- Увесь текст хімічного аналізу та логічних міркувань розміщується виключно всередині тегів `<think>...</think>`. Це імітує когнітивний процес фахівця і дозволяє користувачеві системи (хіміку) верифікувати логіку прийняття рішень.

- Згенеровані прекурсори (реагенти) розміщуються у тегах `<answer>...</answer>`. При цьому модель отримує чітку інструкцію: всередині цих тегів не повинно бути жодного додаткового тексту чи пояснень, лише валідні SMILES-рядки реагентів, розділені символом крапки («.»), якщо реагентів декілька [2].

Загальна структура розробленого шаблону промπτу виглядає наступним чином:

[System]: Ви експерт з органічної хімії. Ваше завдання – виконати однокроковий ретросинтетичний аналіз для заданої молекули.

[Context]: На основі бази даних знайдено схожі прецеденти реакцій:

{RAG_Examples}

[Instruction]: Проаналізуйте цільову молекулу крок за кроком. Опишіть функціональні групи та обґрунтуйте розрив зв'язку на основі наведеного контексту у тегах `<think>...</think>`. Після цього видайте лише SMILES-рядки необхідних реагентів у тегах `<answer>...</answer>`.

[Input]: Цільова молекула (SMILES): {Target_SMILES}

Такий підхід до інженерії підказок (Prompt Engineering) дозволяє ізолювати аналітичну (текстову) частину відповіді від структурної (хімічної), що спрощує подальший автоматичний парсинг результатів алгоритмами

системи. Водночас поєднання контекстного збагачення (RAG) із примусовим міркуванням (CoT) трансформує велику мовну модель із загального генератора тексту в прозору, керовану та хімічно точну підсистему розв'язання спеціалізованих задач синтезу.

3.4 Алгоритм взаємодії компонентів інтелектуальної системи під час генерації реакцій

Для забезпечення надійної роботи розробленої гібридної інтелектуальної системи необхідно чітко регламентувати процеси обміну даними між її основними модулями: підсистемою пошуку (RAG), модулем інженерії підказок та ядром великої мовної моделі (LLM). Запропонований алгоритм взаємодії реалізує концепцію прямого (training-free) конвеєра, який дозволяє динамічно збагачувати модель знаннями на етапі логічного висновку (inference), не втручаючись у її внутрішні параметри [3].

Загальний процес генерації однокрокового ретросинтетичного передбачення складається з п'яти послідовних етапів. Для наочної демонстрації потоків даних та викликів між підсистемами розроблено діаграму послідовності (Sequence Diagram), наведену на рисунку 3.4.




Рисунок 3.4 – Діаграма послідовності алгоритму взаємодії компонентів інтелектуальної системи

Крок 1. Ініціалізація та валідація вхідних даних. Користувач-хімік через графічний інтерфейс системи (наприклад, на базі фреймворку Streamlit) вводить цільову молекулу у форматі рядка SMILES. Керуючий модуль системи за допомогою спеціалізованих хімічних бібліотек (наприклад, RDKit) виконує первинну синтаксичну перевірку та канонізацію рядка, щоб уникнути помилок обробки на подальших етапах.

Крок 2. Динамічне вилучення контексту (Retrieval). Канонізований рядок SMILES передається до підсистеми RAG. Модуль векторизації перетворює молекулу на числовий вектор (Morgan Fingerprint) і виконує запит до векторної СУБД (наприклад, Qdrant). Відбувається пошук k-найближчих сусідів з використанням метрики подібності (Tanimoto similarity) по колекціях глобальної структурної подібності та подібності трансформацій (XOR-відбитки). Система вилучає найкращі прецеденти реакцій разом із їхніми метаданими: розчинниками, каталізаторами та показниками виходу продукту.

Крок 3. Формування структурної підказки (Prompt Construction). Отримані прецеденти реакцій передаються до модуля інженерії підказок. Цей модуль виступає зв'язуючою ланкою і динамічно конструює текстовий запит для мовної моделі. Алгоритм підставляє вилучені реакції у блок Context Examples, а цільову молекулу – у блок Input. Також до запиту додаються жорсткі системні інструкції, які вимагають застосування методу ланцюжка міркувань (Chain-of-Thought) та форматування виводу за допомогою спеціальних XML-подібних тегів.

Крок 4. Авторегресійна генерація (LLM Inference). Керуючий модуль ініціює асинхронний виклик до API вибраного LLM-провайдера (наприклад,

локально розгорнутої моделі LLaMA або Qwen через OpenAI-сумісний інтерфейс). Мовна модель, спираючись на наданий контекст, генерує відповідь. Завдяки правильному налаштуванню промпту, модель спочатку формує логічне хімічне обґрунтування, а потім синтезує SMILES-рядки потенційних прекурсорів.

Крок 5. Парсинг результатів та верифікація (Parsing & Output). Отриманий від моделі текстовий потік підлягає автоматичному лексичному аналізу (парсингу). Алгоритм шукає в тексті спеціальні маркери `<think>...</think>` (або `<reason>...</reason>`), щоб виокремити блок пояснень, і маркери `<answer>...</answer>` для вилучення згенерованих прекурсорів. Знайдені SMILES-рядки реагентів додатково перевіряються на хімічну валідність (перевірка валентностей та збереження маси). Після успішної верифікації система візуалізує для користувача як саму реакцію (у вигляді 2D-графів), так і розгорнутий текстовий аналіз («Міркування хіміка»).

Запропонований алгоритм гарантує, що жоден етап логічного висновку не відбувається ізольовано від хімічних фактів. Процес обміну даними побудований таким чином, що мовна модель виступає не як автономна база знань, а як потужний аналітичний процесор, що обробляє та інтерпретує надійні дані, подані модулем доповненого пошуку.

РОЗДІЛ 4 ОЦІНКА ЕФЕКТИВНОСТІ ТА ВАЛІДАЦІЯ ЗАПРОПОНОВАНОЇ ІНТЕЛЕКТУАЛЬНОЇ СИСТЕМИ

4.1 Методика тестування та перелік метрик

Для об'єктивної оцінки ефективності розробленої гібридної інтелектуальної системи необхідно визначити стандартизовану методику тестування та обрати репрезентативний набір метрик, які дозволять кількісно виміряти покращення результатів порівняно з базовими мовними моделями.

Набір даних для тестування Експериментальна валідація системи проводиться на основі загальноприйнятого в комп'ютерній хімії еталонного набору даних USPTO-50K [2]. Цей набір містить понад 50 000 високоякісних, вручну відібраних органічних реакцій, вилучених із патентної літератури США, які представлені у форматі SMILES. Вибір цього набору зумовлений тим, що він є "золотим стандартом" для задач однокрокового ретросинтезу. Для забезпечення чистоти експерименту набір даних традиційно розділяється на тренувальну (яка в нашій архітектурі виступає як база знань для RAG-пошуку), валідаційну та тестову вибірки.

Методика проведення експерименту Методика тестування передбачає порівняльний (A/B) аналіз на тестовій вибірці цільових молекул. Для кожної молекули з тестового набору генерація прекурсорів (реагентів) виконується у двох конфігураціях:

1. Базова конфігурація (Zero-shot): Великій мовній моделі подається лише SMILES-рядок цільової молекули та базова інструкція передбачити реагенти (без доступу до зовнішньої бази даних та без вимоги покрокового міркування).

2. Запропонована гібридна конфігурація (RAG + CoT): Запит до мовної моделі формується розробленою підсистемою промптингу, яка збагачує вхідні дані знайденими прецедентами з векторної бази (RAG) та вимагає згенерувати хімічне обґрунтування перед видачею результату (Chain-of-Thought).

Для всебічного аналізу згенерованих результатів застосовується комплекс метрик, що оцінюють як хімічну точність, так і синтаксичну правильність відповідей:

1. Точність Top-k (Top-k Exact Match Accuracy). Це головна кількісна метрика для задач ретросинтезу, яка визначається як відсоток тестових прикладів, для яких істинні (зафіксовані в патенті) реагенти присутні серед перших k передбачень, згенерованих системою. Традиційно розраховуються показники для $k=1,3,5$ та 10. Передбачення вважається правильним (Exact Match), якщо канонізований SMILES-рядок згенерованих прекурсорів абсолютно збігається з канонізованим SMILES-рядком реальних прекурсорів з ігноруванням картографування атомів (atom-mapping) [11].

2. Хімічна валідність (Structure Success Rate / Chemical Validity). Оскільки авторегресійні мовні моделі генерують результати посимвольно (токен за токеном), вони схильні до порушення хімічного синтаксису. Ця метрика вимірює відсоток згенерованих рядків SMILES, які є синтаксично правильними та відповідають валідним хімічним структурам (можуть бути успішно розпарсені бібліотекою RDKit). Високий показник цієї метрики свідчить про здатність системи долати проблему "галюцинацій" [6].

3. Синтаксичні та семантичні метрики тексту (BLEU, ROUGE, METEOR). Оскільки розроблена система генерує не лише формули, а й текстові пояснення (Reasoning), додатково можуть застосовуватися метрики обробки природної мови для оцінки якості згенерованого тексту. Проте, як

зазначається в передових дослідженнях, ці метрики часто є недостатніми для повноцінної оцінки хімічної коректності, тому основний акцент робиться на Top-k точності та подальшому якісному експертному аналізі згенерованих ланцюжків міркувань (який буде наведено у підрозділі 4.3).

Застосування такої методології дозволить науково обґрунтовано довести, що інтеграція методів RAG та CoT не лише покращує здатність моделі запам'ятовувати хімічний синтаксис, але й суттєво підвищує її здатність знаходити реалістичні та термодинамічно вигідні шляхи синтезу.

4.2 Порівняльний аналіз якості генерації базової моделі та запропонованої інтелектуальної системи

З метою кількісного оцінювання ефективності запропонованої архітектури було проведено порівняльний експеримент на тестовій вибірці з набору даних USPTO-50K. У ході експерименту результати роботи ізольованої базової великої мовної моделі [ВСТАВИТИ НАЗВУ МОДЕЛІ, наприклад: LLaMA-3.1-8B] у режимі прямого передбачення (Zero-shot) порівнювалися з результатами розробленої гібридної системи, яка використовує доповнений пошук (RAG) та покрокове міркування (CoT).

Головним критерієм якості ретросинтетичного аналізу є здатність системи точно відтворювати прекурсори, зафіксовані у хімічній літературі. Зведені результати оцінювання за метриками Top-1, Top-3 та Top-5 наведені у таблиці 4.1.

Таблиця 4.1 – Порівняння точності ретросинтетичного передбачення

Конфігурація системи	Top-1 (%)	Top-3 (%)	Top-5 (%)	:---	:---	:---
:---	Базова модель (Zero-shot)	[ВСТАВИТИ %]	[ВСТАВИТИ %]			

[ВСТАВИТИ %] | | Запропонована система (RAG + CoT) | [ВСТАВИТИ %] |
[ВСТАВИТИ %] | [ВСТАВИТИ %] |

Як свідчать отримані дані, базова модель без доступу до зовнішнього контексту демонструє низьку точність на рівні [ВСТАВИТИ ВІДСОТОК]% для метрики Top-1. Такий результат є закономірним і підтверджує висновки попередніх досліджень [10]: моделі, що покладаються виключно на власну параметричну пам'ять, страждають від "сліпоти до умов" і часто не здатні правильно ідентифікувати специфічні реакційні центри для складних молекул.

Впровадження гібридної архітектури призвело до радикального покращення показників. Точність Top-1 зросла на [ВСТАВИТИ РІЗНИЦЮ] відсоткових пунктів і досягла [ВСТАВИТИ ВІДСОТОК]%. Показники Top-3 та Top-5 також продемонстрували значний приріст. Це пояснюється тим, що підсистема RAG динамічно вилучає з векторної бази даних [ВСТАВИТИ КІЛЬКІСТЬ k] найбільш релевантних прецедентів на основі молекулярних відбитків. Надання цих прикладів у контекстному вікні ефективно калібрує простір передбачень моделі, зменшуючи невизначеність під час розриву хімічних зв'язків. Завдяки цьому система не "вгадує" реакцію, а логічно екстраполює наявні патентовані знання на цільову молекулу.

Другим критичним аспектом оцінювання є синтаксична правильність згенерованих результатів, оскільки авторегресійні моделі схильні до генерації невалідних структур (галюцинацій). Порівняння хімічної валідності згенерованих SMILES-рядків проілюстровано на рисунку 4.1.

[ВСТАВИТИ РИСУНОК 4.1: Стовпчаста діаграма (Bar chart), де один стовпець показує валідність Zero-shot, а другий - валідність RAG+CoT]

Рисунок 4.1 – Відсоток хімічно валідних згенерованих структур (Structure Success Rate)

У режимі Zero-shot базова модель згенерувала [ВСТАВИТИ ВІДСОТОК]% валідних структур. Решта відповідей містила порушення валентності атомів, незакриті дужки в нотації SMILES або незбалансовану стехіометрію. Застосування розробленої стратегії структурного промптингу (Prompt Engineering) та вимога покрокового міркування (CoT) дозволили підвищити рівень хімічної валідності до [ВСТАВИТИ ВІДСОТОК]%.

Як і в архітектурах типу RetroDFM-R [10], жорстке розділення процесу генерації на блок міркувань (теги <think>...</think>) та блок фінальної відповіді (теги <answer>...</answer>) змушує модель спочатку провести детальний хімічний аналіз функціональних груп. Це знижує ймовірність синтаксичних помилок на етапі безпосередньої генерації цільових токенів реагентів.

Проведене тестування емпірично доводить перевагу розробленого підходу. Відмова від використання великих мовних моделей як ізольованих "чорних ящиків" на користь гібридного конвеєра дозволила досягти [ВСТАВИТИ, наприклад: двократного] збільшення точності передбачення реакцій. Система продемонструвала високу стійкість до галюцинацій, а згенеровані нею прекурсори характеризуються високим рівнем хімічної достовірності, що робить програмний продукт придатним для практичного використання у задачах комп'ютерного планування синтезу.

4.3 Аналіз впливу міркувань на зрозумілість та надійність результатів для експертів-хіміків

Попри високі кількісні показники точності, одним із головних бар'єрів для масового впровадження систем штучного інтелекту в реальну лабораторну практику залишається проблема «чорного ящика». Традиційні

нейромережеві моделі прямого передбачення генерують кінцевий результат (SMILES-рядки прекурсорів), але не здатні розкрити внутрішню логіку прийняття своїх рішень [2]. Це критично знижує довіру хіміків-дослідників, оскільки без розуміння хімічного контексту експерту важко оцінити ризики побічних реакцій або доцільність обраного шляху. Впровадження методу покрокового міркування (Chain-of-Thought, CoT) у розроблену систему безпосередньо вирішує цю проблему, розбиваючи складне завдання на послідовність прозорих та науково обґрунтованих кроків [1].

У запропонованій гібридній архітектурі, яка практично реалізована у програмному застосунку retro-planner [12], модуль міркування формує розгорнутий текстовий аналіз, що відображається для користувача в окремому інтерфейсному блоці «Chemist's Reasoning» (Міркування хіміка). Завдяки розробленій стратегії структурного промптингу, перед тим як згенерувати фінальні реагенти, мовна модель зобов'язана виконати повноцінний ретросинтетичний аналіз: ідентифікувати ключові функціональні групи цільової молекули; оцінити реакційні центри з урахуванням резонансних та стеричних ефектів; чітко вказати зв'язки, що підлягають розриву, та обґрунтувати термодинамічну і кінетичну доцільність запропонованого синтезу.

Якісний аналіз згенерованих міркувань доводить, що система здатна імітувати когнітивний процес фахівця. Розглянемо приклад роботи системи для складної цільової молекули [ВСТАВИТИ НАЗВУ АБО SMILES ВАШОЇ ТЕСТОВОЇ МОЛЕКУЛИ]. Замість видачі «сухої» формули, алгоритм генерує наступне обґрунтування:

[ВСТАВИТИ СКРІНШОТ АБО ТЕКСТ (з тегів <think>) З ВАШОЇ ПРОГРАМИ. Нижче наведено типовий академічний приклад для орієнтиру]

«Цільова молекула містить хіназолінонове ядро та вторинну аміногрупу. Ретросинтетичний аналіз фокусується на розриві зв'язку C–N між фрагментами, що вказує на реакцію відновного амінування як найбільш вірогідний шлях. Цей вибір дозволяє уникнути утворення жорсткого піримідинового кільця. Запропонований маршрут забезпечує високу хемоселективність завдяки використанню ціаноборгідриду натрію в м'яких кислотних умовах, що робить реакцію термодинамічно вигідною та мінімізує ризики побічного переалкілювання».

Забезпечення такої прозорості (explainability) результатів має подвійний позитивний вплив на загальну надійність системи:

1. Зниження рівня галюцинацій алгоритму. Примушуючи велику мовну модель вербалізувати (прописувати текстом) фізико-хімічні закони перед формуванням кінцевих SMILES-рядків, система самокалібрується. Описавши наявність електроноакцепторної групи, модель з меншою ймовірністю запропонує хімічно нелогічний розрив зв'язку поруч із нею.

2. Верифікованість для експерта. Система перестає бути безапеляційним оракулом і перетворюється на інтелектуального асистента. Якщо запропонований шлях має неочевидні недоліки (наприклад, потенційну конкурентну реакцію), хімік може миттєво виявити логічну помилку алгоритму, прочитавши блок «Chemist's Reasoning», і відкинути хибний варіант ще до початку дороговартісних лабораторних експериментів.

Додатково варто зазначити, що інтеграція текстових міркувань із наочною графічною візуалізацією хімічних рівнянь (Reaction Visualizer) за допомогою бібліотеки RDKit створює цілісне та інтуїтивно зрозуміле середовище для дослідника. Таким чином, гібридна архітектура RAG + CoT не лише підвищує математичні метрики точності (розглянуті у підрозділі 4.2),

але й концептуально вирішує проблему довіри, забезпечуючи високий рівень інтерпретованості кожного згенерованого кроку ретросинтезу.

РОЗДІЛ 5 ФУНКЦІОНАЛЬНО-ВАРТІСНИЙ АНАЛІЗ ПРОГРАМНОГО ПРОДУКТУ

5.1 Постановка задачі проектування

Нанонаука

5.2 Обґрунтування функцій програмного продукту

Нанонаука

5.3 Обґрунтування системи параметрів програмного продукту

Нанонаука

5.4 Аналіз експертного оцінювання параметрів

Нанонаука

5.5 Аналіз рівня якості варіантів реалізації функцій

Нанонаука

5.6 Вибір кращого варіанту програмного продукту техніко-економічного рівня

Нанонаука

ПЕРЕЛІК ПОСИЛАНЬ

1. Tharwani K. K. L., Sumita R. K., Ahmed N., Tang Y. Large Language Models Transform Organic Synthesis From Reaction Prediction to Automation.
2. Zhang S., Li H., Chen L., Zhao Z., Lin X., Zhu Z., Chen B., Chen X., Yu K. Reasoning-Driven Retrosynthesis Prediction with Large Language Models via Reinforcement Learning. arXiv, 2025. URL: <https://arxiv.org/abs/2505.20208> (дата звернення: 14.07.2026).
3. J. Chan, W. Kweon, A. Shin, N. Bhattacharjee, P. Jiang, Y. Guo, and J. Han, "MOLE-RAG: Molecular-structure Enhanced Retrieval-Augmented Generation for Chemistry," arXiv preprint, arXiv:2505.15034, 2025. doi: 10.48550/arXiv.2505.15034.
4. Sagawa T., Kojima R. *ReactionT5: a pre-trained transformer model for accurate chemical reaction prediction with limited data* // Journal of Cheminformatics. 2025. Vol. 17. Article 126. DOI: 10.1186/s13321-025-01075-4. URL: <https://doi.org/10.1186/s13321-025-01075-4> (дата звернення: 15.07.2026).
5. Schaarschmidt C. J., Caldas Ramos M., White A. D. Large language models and autonomous agents in chemistry // Chemical Science. 2025. Vol. 16. P. 2514–2572. DOI: 10.1039/D4SC03921A. URL: <https://doi.org/10.1039/D4SC03921A> (дата звернення: 15.07.2026).
6. Z. Chen, Z. Fang, W. Tian, Z. Long, C. Sun, Y. Chen, H. Yuan, H. Li, and M. Lan, "ReactGPT: Understanding of Chemical Reactions via In-Context Tuning," *arXiv preprint*, arXiv:2402.06161, 2024. doi: 10.48550/arXiv.2402.06161.
7. Liu S., Tu Z., Xu M., Zhang Z., Lin L., Ying R., Tang J., Zhao P., Wu D.

- FusionRetro: Molecule Representation Fusion via In-Context Learning for Retrosynthetic Planning // Proceedings of the 40th International Conference on Machine Learning (ICML 2023). Proceedings of Machine Learning Research. 2023. Vol. 202. P. 22028–22041. URL: <https://proceedings.mlr.press/v202/liu23ah.html> (дата звернення: 15.07.2026).
8. Chen K., Lu J., Li J., Yang X., Du Y., Wang K., Shi Q., Yu J., Li L., Qiu J., Pan J., Huang Y., Fang Q., Heng P. A., Chen G. Chemist-X: Large Language Model-Powered Agent for Recommending Reaction Conditions in Chemical Synthesis and Autonomous Laboratories // arXiv. 2025. arXiv:2505.19174. DOI: 10.48550/arXiv.2505.19174. URL: <https://arxiv.org/abs/2505.19174> (дата звернення: 15.07.2026).
 9. Zhang Y., Han Y., Chen S., Yu R., Zhao X., Liu X., Zeng K., Yu M., Tian J., Zhu F., Yang X., Jin Y., Xu Y. Large Language Models to Accelerate Organic Chemistry Synthesis // arXiv. 2024. arXiv:2401.06946. DOI: 10.48550/arXiv.2401.06946. URL: <https://arxiv.org/abs/2401.06946> (дата звернення: 15.07.2026).
 10. Song X., Pan X., Zhao X., Ye H., Zhang S., Tang J., Yu T. AOT: Efficient Synthesis Planning via LLM-Empowered AND-OR Tree Search // arXiv. 2025. arXiv:2502.17633. DOI: 10.48550/arXiv.2502.17633. URL: <https://arxiv.org/abs/2502.17633> (дата звернення: 15.07.2026).
 11. Coley C. W., Rogers L., Green W. H., Jensen K. F. Computer-Assisted Retrosynthesis Based on Molecular Similarity // ACS Central Science. 2017. Vol. 3, № 12. P. 1237–1245. DOI: 10.1021/acscentsci.7b00355. URL: <https://doi.org/10.1021/acscentsci.7b00355> (дата звернення: 15.07.2026).
 12. repo